Curso Seis

Projeto Final de Análise Avançada de Dados do Google



Instruções

Use este documento de estratégia PACE para registrar suas decisões e reflexões como profissional de dados ao trabalhar no projeto final. Como lembrete, este documento é um guia de recursos que você pode consultar no futuro e um espaço para ajudar a orientar suas respostas e reflexões apresentadas em vários pontos ao longo do projeto.

Resumo do Projeto de Portfólio

Muitas das metas que você alcançou em seus projetos individuais de portfólio de cursos estão incorporadas ao projeto final de Análise Avançada de Dados, incluindo:

- Criar uma proposta de projeto
- Demonstrar compreensão da forma e função do Python
- Mostrar como profissionais de dados aproveitam o Python para carregar, explorar, extrair e organizar informações por meio de funções personalizadas
- Demonstrar compreensão de como organizar e analisar um conjunto de dados para encontrar a "história"
- Criar um notebook Jupyter para Análise Exploratória de Dados (EDA)
- Criar visualização(ões) usando o Tableau
- Usar Python para calcular estatísticas descritivas e realizar um teste de hipótese
- Construir um modelo de regressão linear múltipla com teste ANOVA
- Avaliar o modelo
- Demonstrar a capacidade de usar um ambiente de notebook para criar uma série de modelos de aprendizado de máquina em um conjunto de dados para resolver um problema
- Articular descobertas em um resumo executivo para partes interessadas externas

Proposta de projeto

Previsão de Rotatividade de Funcionários (Salifort Motors)

Overview

O objetivo deste projeto é identificar as causas subjacentes da alta rotatividade de funcionários na Salifort Motors e desenvolver um modelo preditivo para estimar a probabilidade de um funcionário deixar a empresa. A análise ajudará a liderança sênior a implementar medidas de retenção eficazes, melhorar a satisfação interna e reduzir custos financeiros associados a novas contratações e treinamentos.

Marcos do projeto	Tarefas	Etapas PACE
1. Estruturação do fluxo e escopo do projeto	• Alinhar os objetivos de negócio com a liderança sênior. • Estabelecer critérios de sucesso e métricas de avaliação para o modelo (priorizando Recall/F1-score para prever saídas). • Elaborar a proposta formal de trabalho.	Plan
2. Coleta e inspeção preliminar dos dados	• Importar o conjunto de dados da pesquisa de RH em ambiente Python. • Mapear tipos de variáveis, verificar valores ausentes, linhas duplicadas e integridade dos registros.	Analyze
3. Formulação de hipóteses e limpeza de dados	• Tratar dados ausentes/inconsistentes e renomear colunas conforme padrões analíticos. • Formular hipóteses iniciais sobre as causas da rotatividade (ex.: sobrecarga de horas e volume de projetos).	Plan and Analyze
4. Análise exploratória e visualização gráfica	• Realizar Análise Exploratória de Dados (EDA) cruzando rotatividade com cargo, departamento, horas mensais e satisfação. • Construir gráficos de dispersão, histogramas e boxplots para validar visualmente hipóteses de sobrecarga (burnout).	Analyze and Construct
5. Testes estatísticos e validação de padrões	• Calcular estatísticas descritivas comparativas entre funcionários ativos e os que saíram. • Aplicar testes de hipóteses estatísticas (ex.: teste t para a média de horas trabalhadas) para confirmar significância das diferenças encontradas.	Analyze
6. Modelagem estatística inicial (Linha de Base)	• Realizar engenharia de atributos (codificação de variáveis categóricas como departamento e salário). • Ajustar um modelo de Regressão Logística para verificar a interpretabilidade direta dos fatores de risco (odds ratios).	Analyze and Construct

7. Diagnóstico e avaliação do modelo estatístico	• Analisar métricas de desempenho (Precision, Recall, ROC-AUC) e avaliar limitações de premissas lineares na identificação de casos de rotatividade.	Execute
8. Modelagem preditiva avançada de Machine Learning	• Treinar e otimizar modelos baseados em árvores (Árvore de Decisão, Random Forest e XGBoost) com validação cruzada e ajuste de hiperparâmetros (GridSearchCV). • Ajustar limiares de decisão (thresholds) para maximizar a captura de colaboradores em risco.	Construct
9. Comparação de modelos e análise de importância de variáveis	• Comparar resultados entre os modelos estatísticos e de machine learning. • Extrair a importância das variáveis (feature importances) para isolar os gatilhos primários que levam à saída de funcionários.	Execute and Analyze
10. Conclusões e recomendações para a liderança	• Consolidar os achados técnicos em linguagem de negócios. • Apresentar à equipe de liderança sênior o resumo executivo com recomendações práticas (ex.: limites de carga horária e reestruturação de projetos) e próximos passos.	Execute

Perguntas e Considerações do Projeto de Dados



PACE: Etapa Plan (Planejar)

Fundamentos da Ciência de Dados

- **Quem é seu público-alvo para este projeto?**

A equipe de liderança sênior da Salifort Motors e os gestores do departamento de Recursos Humanos (RH).

- **O que você está tentando resolver ou alcançar? E qual você antecipa que será o impacto deste trabalho sobre a necessidade de negócios maior?**

O objetivo é identificar as causas raiz da rotatividade de funcionários e construir um modelo preditivo para estimar a probabilidade de um colaborador deixar a empresa. O impacto esperado é permitir que a liderança tome medidas preventivas de retenção, aumentando a satisfação interna e reduzindo custos com novas contratações e treinamentos.

- **Quais perguntas precisam ser feitas ou respondidas?**

Quais fatores (ex.: número de projetos, horas mensais, nível de satisfação, avaliação de desempenho) mais influenciam a decisão de um funcionário sair? Existe relação entre sobrecarga de trabalho e rotatividade? É possível prever com antecedência quais colaboradores estão em risco de saída?

- **Quais recursos são necessários para concluir este projeto?**

Conjunto de dados de pesquisas de RH da Salifort Motors, ambiente Python (Jupyter Notebook) com bibliotecas para EDA e Machine Learning (pandas, numpy, matplotlib, seaborn, scikit-learn, xgboost), além de ferramentas para elaboração de relatórios e resumos executivos.

- **Quais são os entregáveis que precisarão ser criados ao longo deste projeto?**

Documento de proposta de projeto, notebook Jupyter contendo EDA, modelos estatísticos e preditivos treinados e avaliados, e um resumo executivo com recomendações estratégicas para a liderança.

- **Qual é a melhor forma de se preparar para entender e organizar as informações fornecidas?**

Estruturar o plano de trabalho seguindo o framework PACE, inspecionar e limpar o conjunto de dados, mapear o significado de cada variável e definir critérios claros de avaliação e métricas de sucesso (como Recall e F1-Score).

- **Quais guias e livros de código de autoavaliação ajudarão você a realizar este trabalho?**

Documentação oficial do scikit-learn/XGBoost para ajuste de modelos e métricas, bem como o modelo de documento de estratégia PACE e os cadernos de referência dos cursos anteriores de Análise de Dados.

- **Quais são algumas atividades adicionais que um estudante proativo realizaria antes de começar a codificar?**

  Revisar a literatura e melhores práticas de People Analytics sobre retenção de talentos, verificar premissas éticas relativas à privacidade dos dados dos funcionários e listar possíveis limitações das variáveis coletadas.

Vá Além dos Números: Traduza Dados em Insights

- **Quais são as colunas e variáveis de dados e quais são as mais relevantes para o seu entregável?**

O conjunto de dados contém as seguintes variáveis:

- satisfaction_level
- last_evaluation
- number_projects
- average_monthly_hours
- tenure
- work_accident
- left
- promotion_last_5_years
- department
- salary

A variável mais importante para o entregável é left, pois ela representa se o funcionário deixou ou não a empresa e será a variável-alvo do modelo preditivo. As variáveis mais relevantes como preditoras incluem satisfaction_level, tenure, average_monthly_hours, number_projects, salary e promotion_last_5_years, pois podem influenciar diretamente a rotatividade de funcionários.

- **Em quais unidades estão suas variáveis?**

- satisfaction_level: índice de satisfação (0 a 1).
- last_evaluation: pontuação de avaliação de desempenho (0 a 1).
- number_projects: quantidade de projetos.
- average_monthly_hours: horas trabalhadas por mês.

- tenure: anos de permanência na empresa.
- work_accident: variável binária (0 = não, 1 = sim).
- left: variável binária (0 = permaneceu, 1 = saiu).
- promotion_last_5_years: variável binária (0 = não, 1 = sim).
- department: categoria textual.
- salary: categoria salarial (baixo, médio ou alto).

- **Quais são suas suposições iniciais sobre os dados que podem orientar sua EDA, sabendo que precisará confirmar ou refutar com suas descobertas futuras?**

Antes da análise exploratória, algumas hipóteses iniciais podem ser:

- Funcionários com menor satisfação têm maior probabilidade de deixar a empresa.
- Funcionários que trabalham muitas horas podem apresentar maior taxa de desligamento.
- Funcionários sem promoção nos últimos cinco anos podem ser mais propensos a sair.
- O salário pode ter influência na retenção de funcionários.
- Maior tempo de empresa pode estar relacionado a padrões específicos de rotatividade.

Essas hipóteses precisam ser confirmadas ou refutadas durante a EDA.

- **Existem dados ausentes ou incompletos?**

Não. A verificação de valores ausentes mostrou que todas as colunas possuem 14.999 valores não nulos, indicando que não há dados faltantes no conjunto analisado.

- **Todas as partes deste conjunto de dados estão no mesmo formato?**

Em sua maioria, sim. As variáveis numéricas estão armazenadas como float64 ou int64, enquanto as variáveis categóricas (department e salary) estão armazenadas como objetos (object). No entanto, foi necessário padronizar e corrigir alguns nomes de colunas para melhorar a consistência dos dados.

- **Quais práticas de EDA serão necessárias para iniciar este projeto?**

As principais práticas de EDA incluem: Compreensão da estrutura dos dados; Análise de estatísticas descritivas; Verificação de valores ausentes; Identificação e remoção de registros duplicados; Detecção e análise de outliers; Análise das distribuições das variáveis; Investigação das relações entre variáveis e a variável-alvo (left); Análise de correlação entre variáveis numéricas; Criação de visualizações como histogramas, boxplots e mapas de calor para identificar padrões relevantes.

O Poder da Estatística

- Qual é o objetivo principal deste projeto?

- Qual é a sua pergunta de pesquisa para este projeto?
- Qual é a importância da amostragem aleatória? Neste caso, qual é um exemplo de viés de amostragem que poderia ocorrer se você não usasse amostragem aleatória?

Análise de Regressão: Simplifique Relações Complexas de Dados

- Quem são as partes interessadas (stakeholders) para este projeto?
- O que você está tentando resolver ou alcançar?
- Quais são suas observações iniciais ao explorar os dados?
- Quais recursos você se pega usando ao concluir esta etapa? (Certifique-se de incluir os links.)
- Você tem alguma consideração ética nesta etapa?

Os Fundamentos do Aprendizado de Máquina

- O que estou tentando resolver?
- Quais recursos você se pega usando ao concluir esta etapa?
- Meus dados são confiáveis?
- Você tem considerações éticas adicionais nesta etapa?
- Quais dados eu preciso/gostaria de ver em um mundo perfeito para responder a esta pergunta?
- Quais dados eu tenho/consigo obter?
- Qual métrica devo usar para avaliar o sucesso do meu objetivo de negócio? Por quê?

Perguntas e Considerações do Projeto de Dados



PACE: Etapa Analyze (Analisar)

Fundamentos da Ciência de Dados

- As informações disponíveis serão suficientes para atingir o objetivo com base em sua intuição e na análise das variáveis?

Vá Além dos Números: Traduza Dados em Insights

- Quais etapas precisam ser seguidas para realizar a EDA da forma mais eficaz para alcançar o objetivo do projeto?
- Você precisa adicionar mais dados usando a prática de EDA de cruzamento/junção (joining)? Que tipo de estruturação precisa ser feita neste conjunto de dados, como filtragem, ordenação, etc.?
- Quais suposições iniciais você tem sobre os tipos de visualizações que seriam mais adequadas para o público pretendido?

O Poder da Estatística

- Por que as estatísticas descritivas são úteis?
- Qual é a diferença entre a hipótese nula e a hipótese alternativa?

Análise de Regressão: Simplifique Relações Complexas de Dados

- Quais são alguns dos objetivos da EDA antes de construir um modelo de regressão linear múltipla?
- Você tem alguma consideração ética nesta etapa?

Os Fundamentos do Aprendizado de Máquina

- O que estou tentando resolver? Ainda funciona? O plano precisa ser revisado?
- Os dados violam as suposições do modelo? Isso é aceitável ou inaceitável?
- Por que você selecionou as variáveis X que escolheu?
- Quais são alguns dos objetivos da EDA antes de construir um modelo?
- O que a EDA lhe revelou?
- Quais recursos você se pega usando ao concluir esta etapa?
- Você tem alguma consideração ética nesta etapa?

Perguntas e Considerações do Projeto de Dados



PACE: Etapa Construct (Construir)

Fundamentos da Ciência de Dados

- Algumas médias de variáveis de dados parecem incomuns?
- Quantos fornecedores, organizações ou agrupamentos estão incluídos nestes dados totais?

Vá Além dos Números: Traduza Dados em Insights

- Quais visualizações de dados, algoritmos de aprendizado de máquina ou outros resultados de dados precisarão ser construídos para concluir os objetivos do projeto?
- Quais processos precisam ser realizados para construir as visualizações de dados necessárias?
- Quais variáveis são mais aplicáveis para as visualizações neste projeto de dados?
- Voltando à etapa Plan (Planejar), como você planeja lidar com os dados ausentes (se houver)?

O Poder da Estatística

- Como você formulou sua hipótese nula e hipótese alternativa?
- Qual conclusão pode ser tirada do teste de hipótese?

Análise de Regressão: Simplifique Relações Complexas de Dados

- Você nota algo estranho?
- Você pode melhorá-lo? Há algo que você mudaria no modelo?

Os Fundamentos do Aprendizado de Máquina

- Existe algum problema? Pode ser corrigido? Se sim, como?
- Quais variáveis independentes você escolheu para o modelo e por quê?
- Quão bem o seu modelo se ajusta aos dados? (Qual é a pontuação de validação do meu modelo?)
- Você pode melhorá-lo? Há algo que você mudaria no modelo?
- Você tem alguma consideração ética nesta etapa?

Perguntas e Considerações do Projeto de Dados



PACE: Etapa Execute (Executar)

Fundamentos da Ciência de Dados

- Com base no seu conhecimento atual dos dados, o que você recomendaria inicialmente ao seu gestor para investigar mais detalhadamente antes de realizar uma análise exploratória de dados?
- Quais dados se apresentam inicialmente como contendo anomalias?
- Quais tipos adicionais de dados poderiam fortalecer este conjunto de dados?

Vá Além dos Números: Traduza Dados em Insights

- Quais insights principais emergiram de sua EDA e visualização(ões)?
- Quais recomendações de negócios você propõe com base nas visualizações construídas?
- Dado o que você sabe sobre os dados e as visualizações que estava usando, quais outras perguntas você poderia pesquisar para a equipe?
- Como você poderia compartilhar essas visualizações com diferentes públicos?

O Poder da Estatística

- Qual(is) insight(s) principal(is) de negócios emergiu(em) do seu teste A/B?
- Quais recomendações de negócios você propõe com base nos seus resultados?

Análise de Regressão: Simplifique Relações Complexas de Dados

- Para interpretar os resultados do modelo, por que é importante interpretar os coeficientes beta?
- Quais potenciais recomendações você faria ao seu gestor/empresa?
- Você acha que seu modelo poderia ser melhorado? Por que sim ou por que não? Como?
- Quais recomendações de negócios você propõe com base nos modelos construídos?
- Quais insights principais emergiram do(s) seu(s) modelo(s)?
- Você tem alguma consideração ética nesta etapa?

Os Fundamentos do Aprendizado de Máquina

- Quais insights principais emergiram do(s) seu(s) modelo(s)?
- Quais são os critérios para a seleção de modelos?

- Meu modelo faz sentido? Meus resultados finais são aceitáveis?
- Houve algum atributo (feature) que não foi importante de forma alguma? E se você os remover?
- Dado o que você sabe sobre os dados e os modelos que estava usando, quais outras perguntas você poderia abordar para a equipe?
- Quais recursos você se pega usando ao concluir esta etapa?
- Meu modelo é ético?
- Quando meu modelo comete um erro, o que está acontecendo? Como isso se traduz para o meu caso de uso?